Memahami Data dan Sumber Data

Bab 2 — Analisis dan Visualisasi Data

Struktur Data

Terstruktur, semi-terstruktur, tidak terstruktur

Jenis & Skala

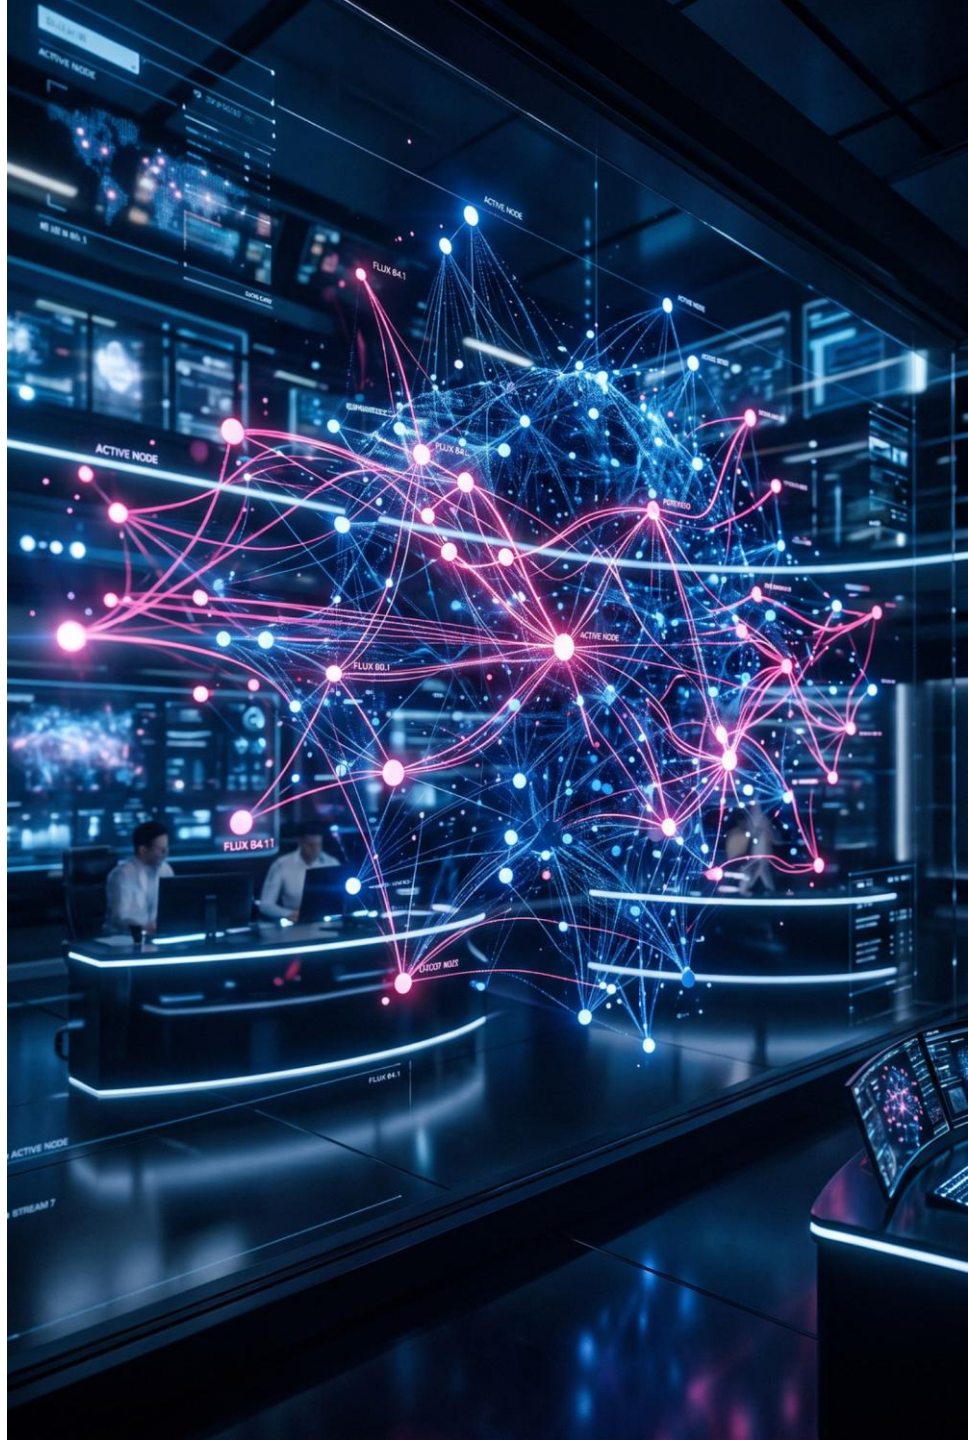
Numerik, kategorikal, nominal, ordinal, interval, rasio

Sumber & Format

CSV, JSON, XML, database, API, open data

Praktik Python

Pemeriksaan awal dataset menggunakan Pandas



Capaian Pembelajaran

Pemahaman Konseptual

Setelah mempelajari bab ini, mahasiswa diharapkan mampu memahami konsep data secara mendalam, membedakan berbagai jenis data berdasarkan struktur, sifat, dan skala pengukurannya, serta mengenali berbagai sumber data yang umum digunakan dalam analisis.

Mahasiswa juga diharapkan mampu menjelaskan perbedaan antara data terstruktur, semi-terstruktur, dan tidak terstruktur, serta memahami karakteristik data numerik, kategorikal, temporal, dan spasial dalam konteks sistem informasi dan aplikasi Informatika.

Kemampuan Teknis

Pada akhir pertemuan, mahasiswa diharapkan mampu mengidentifikasi komponen sebuah dataset yang meliputi **observasi, variabel, atribut, record, feature, dan target**, serta mengenali format data seperti CSV, JSON, XML, spreadsheet, database relasional, dan data yang diperoleh melalui API.

Mahasiswa juga diperkenalkan pada proses **pemeriksaan awal dataset menggunakan Python dan Pandas** agar mampu mengetahui struktur, ukuran, tipe data, nilai kosong, serta statistik dasar sebelum memasuki proses pembersihan dan analisis yang lebih lanjut.

Konsep Data dan Informasi

Data merupakan representasi dari suatu fakta, objek, kejadian, pengukuran, aktivitas, atau fenomena yang dapat direkam dan disimpan. Data dapat berupa angka (nilai ujian), teks (nama mahasiswa), waktu (tanggal transaksi), maupun kategori (status kelulusan). Data menjadi **informasi** ketika telah diproses atau ditempatkan dalam konteks tertentu sehingga memiliki makna bagi pengguna.

> Contoh: Angka **85** tanpa konteks hanya merupakan data numerik. Namun, ketika diketahui bahwa 85 adalah nilai mata kuliah Analisis dan Visualisasi Data milik seorang mahasiswa, angka tersebut memiliki makna yang lebih jelas.

Data

Fakta mentah dan angka

Pengolahan

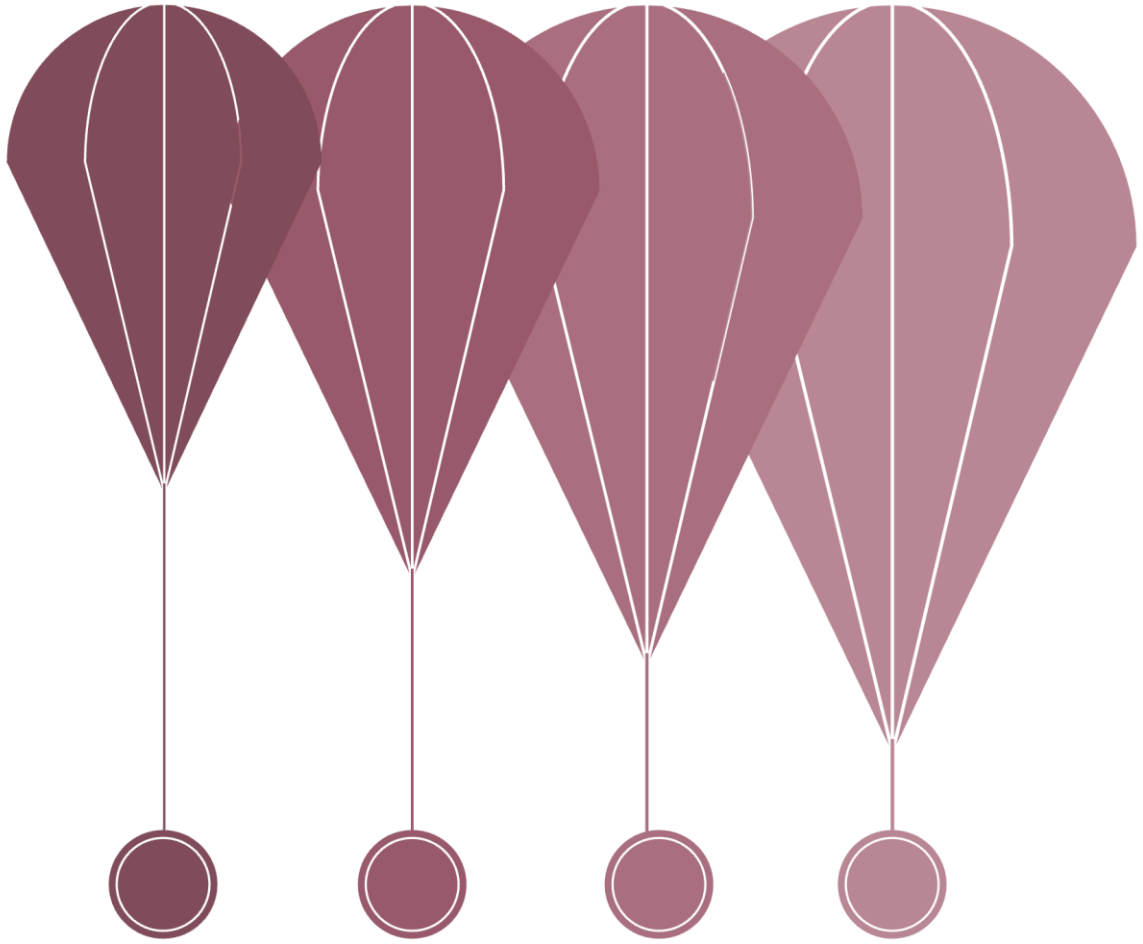
Konteks dan interpretasi

Informasi

Wawasan yang bermakna

Pengetahuan

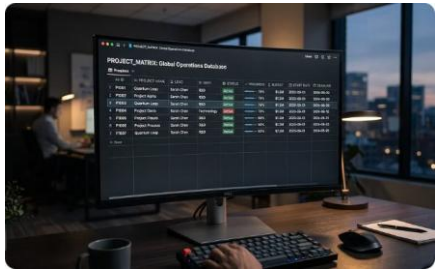
Keputusan dan tindakan



Sebagai contoh, sistem akademik menyimpan data nilai mahasiswa. Setelah diolah, diketahui bahwa rata-rata nilai suatu kelas adalah 62. Informasi tersebut dibandingkan dengan standar kelulusan sehingga diketahui bahwa sebagian besar mahasiswa mengalami kesulitan pada materi tertentu. Berdasarkan pengetahuan tersebut, dosen dapat mengambil keputusan untuk melakukan pembelajaran remedial. Tujuan utama analisis bukan sekadar mengolah data, tetapi **mengubah data menjadi informasi yang dapat memberikan pemahaman dan mendukung tindakan**.

Data Terstruktur, Semi-Terstruktur, dan Tidak Terstruktur

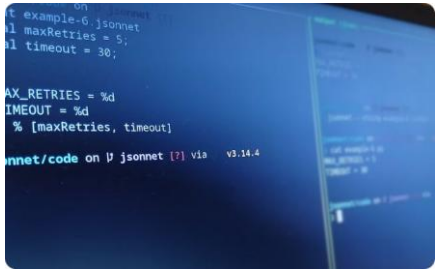
Berdasarkan bentuk dan organisasinya, data dapat dibedakan menjadi tiga jenis. Klasifikasi ini penting karena struktur data memengaruhi cara penyimpanan, pengambilan, pemrosesan, dan analisis.



Data Terstruktur

Memiliki format dan skema yang jelas, disimpan dalam bentuk tabel dengan baris dan kolom. Setiap kolom memiliki nama dan tipe data tertentu. Contoh: database relasional seperti MySQL, PostgreSQL, SQL Server, dan Oracle.

Contoh tabel mahasiswa: NIM, Nama, Prodi, Semester, IPK — setiap baris merepresentasikan satu mahasiswa, setiap kolom menggambarkan atribut tertentu.



Data Semi-Terstruktur

Tidak selalu disimpan dalam bentuk tabel, tetapi masih memiliki elemen struktur yang dapat digunakan untuk mengenali hubungan antarbagian data. Format **JSON** dan **XML** merupakan contoh umum yang digunakan pada aplikasi web dan API.

Lebih fleksibel dibandingkan tabel relasional karena jumlah dan jenis atribut dapat berbeda antarobjek.



Data Tidak Terstruktur

Tidak memiliki skema tabular yang tetap. Contohnya adalah dokumen teks, gambar, audio, video, rekaman percakapan, unggahan media sosial, dan email. Dapat dianalisis menggunakan metode seperti **natural language processing, computer vision, speech recognition**, dan deep learning.

Dalam praktik modern, satu sistem dapat menggunakan ketiga jenis data sekaligus. Aplikasi media sosial, misalnya, menyimpan profil pengguna dalam database terstruktur, data aktivitas melalui JSON, dan gambar atau video sebagai data tidak terstruktur.

Data Numerik dan Kategorikal

Data Numerik

Data yang memiliki nilai dalam bentuk angka dan memungkinkan dilakukan operasi matematika yang bermakna. Dibedakan menjadi dua jenis:

- **Data Diskrit**: diperoleh melalui proses penghitungan, memiliki nilai yang dapat dihitung satu per satu. Contoh: jumlah mahasiswa, jumlah transaksi, jumlah komputer, jumlah kendaraan.
- **Data Kontinu**: diperoleh melalui proses pengukuran, secara teoretis dapat memiliki nilai pada rentang yang sangat kecil. Contoh: tinggi badan (170,5 cm atau 170,51 cm), berat badan, suhu, waktu tempuh, kecepatan.

Data Kategorikal

Digunakan untuk menggambarkan kelompok, label, kelas, atau karakteristik tertentu. Dibedakan menjadi dua jenis:

- **Nominal**: kategori yang tidak memiliki urutan alami. Contoh: jenis kelamin, kota asal, program studi, jenis perangkat, metode pembayaran.
- **Ordinal**: memiliki urutan tertentu. Contoh: tingkat kepuasan — sangat tidak puas, tidak puas, netral, puas, sangat puas.

Mengapa Perbedaan Ini Penting?

Perbedaan antara data numerik dan kategorikal memengaruhi pemilihan metode analisis. Rata-rata dapat dihitung untuk data numerik, tetapi tidak bermakna apabila diterapkan langsung pada data nominal. **Histogram** lebih tepat untuk distribusi data numerik, sedangkan **diagram batang** lebih sesuai untuk membandingkan jumlah data pada setiap kategori.

Skala Pengukuran Data

Skala pengukuran menentukan bagaimana suatu variabel dapat diinterpretasikan dan jenis operasi statistik yang dapat dilakukan terhadapnya. Terdapat empat skala pengukuran yang sering digunakan, dengan tingkat informasi yang berbeda-beda.

Nominal

Mengelompokkan data tanpa urutan tertentu. Contoh: jenis sistem operasi (Windows, Linux, macOS). Analisis: frekuensi, proporsi, modus.

Ordinal

Kategori yang dapat diurutkan, tetapi jarak antar kategori belum tentu sama. Contoh: tingkat kepuasan pengguna. Urutan jelas, tetapi perbedaan antar level tidak selalu setara.

Interval

Memiliki urutan dan jarak antar nilai yang konsisten, tetapi tidak memiliki nilai nol absolut. Contoh: suhu dalam derajat Celsius. Selisih 20°C ke 30°C sama dengan 30°C ke 40°C, tetapi 40°C bukan dua kali lebih panas dari 20°C.

Rasio

Memiliki seluruh karakteristik interval serta nilai nol absolut. Contoh: berat, tinggi, waktu, jarak, jumlah transaksi, pendapatan. Perbandingan rasio dapat dilakukan secara bermakna.

Hierarki Informasi: Nominal < Ordinal < Interval < Rasio. Semakin tinggi tingkat skala pengukuran, semakin banyak operasi statistik yang secara umum dapat diterapkan. Namun, penggunaan metode statistik tetap harus mempertimbangkan distribusi dan karakteristik data.

Sumber Data Primer dan Sekunder

Data Primer

Data yang dikumpulkan secara langsung oleh peneliti atau organisasi untuk tujuan tertentu. Dapat diperoleh melalui survei, wawancara, eksperimen, sensor, observasi, maupun aplikasi yang dikembangkan khusus.

Kelebihan: Peneliti memiliki kendali lebih besar terhadap proses pengumpulan dan dapat menyesuaikan variabel yang diperlukan.

Kelemahan: Membutuhkan waktu, tenaga, biaya, dan prosedur yang lebih kompleks.

Data Sekunder

Data yang sebelumnya telah dikumpulkan oleh pihak lain dan kemudian digunakan kembali untuk tujuan analisis yang berbeda. Dapat diperoleh dari pemerintah, lembaga penelitian, organisasi internasional, perusahaan, repositori data, dan situs open data.

Kelebihan: Dapat digunakan lebih cepat dan biaya pengumpulan relatif rendah.

Kelemahan: Pengguna harus memahami bagaimana data dikumpulkan agar dapat menilai kualitas dan relevansinya.

Sumber Data dalam Informatika

Dalam Informatika, sumber data dapat sangat beragam: database transaksi, log server, sensor IoT, sistem enterprise, aplikasi mobile, media sosial, API, maupun hasil scraping web. Pemilihan sumber data harus disesuaikan dengan pertanyaan analisis — data yang mudah diperoleh tetapi tidak relevan tidak akan memberikan hasil yang berguna.

Dataset, Record, Feature, dan Attribute

Dataset merupakan kumpulan data yang disusun sedemikian rupa agar dapat diproses dan dianalisis. Dalam bentuk tabular, dataset terdiri atas baris dan kolom. Setiap baris mewakili suatu **observasi atau record**, sedangkan kolom merepresentasikan **atribut atau feature**.

NIM	Usia	Semester	IPK	Status
M001	20	4	3,50	Aktif
M002	21	6	3,72	Aktif
M003	23	8	2,91	Aktif

Komponen Dataset

- **NIM**: berfungsi sebagai identifier atau penanda unik, bukan variabel analisis
- **Usia, Semester, IPK, Status**: variabel atau atribut yang mendeskripsikan mahasiswa
- Dalam machine learning, **feature** merujuk pada variabel input model, sedangkan **target/label** adalah variabel yang ingin diprediksi

Contoh Penerapan Machine Learning

Jika tujuan model adalah memprediksi apakah mahasiswa akan lulus tepat waktu, maka usia, IPK, jumlah SKS, dan kehadiran dapat digunakan sebagai **feature**, sementara status lulus tepat waktu menjadi **target**.

Kesalahan dalam mengidentifikasi identifier sebagai feature dapat menghasilkan model atau analisis yang tidak bermakna.

Format Data: CSV, JSON, XML, dan Spreadsheet

CSV (Comma-Separated Values)

Format paling sering digunakan dalam analisis data. Menyimpan data dalam bentuk teks dengan setiap baris mewakili record dan setiap nilai dipisahkan menggunakan delimiter.

```
nim,nama,semester,ipk
2201001,Andi,5,3.42
2201002,Budi,5,3.71
```

Kelebihan: Sederhana, mudah dibaca, ukuran kecil, didukung hampir seluruh perangkat lunak. **Keterbatasan:** Tidak menyimpan tipe data secara eksplisit dan tidak mendukung struktur bertingkat.

JSON (JavaScript Object Notation)

Banyak digunakan dalam aplikasi web dan API. Lebih fleksibel dari CSV karena dapat menyimpan data bertingkat (nested data).

```
{"nim": "2201001", "nama": "Andi",
 "nilai": {"algoritma": 85,
           "basis_data": 88}}
```

XML (Extensible Markup Language)

Menggunakan tag untuk menggambarkan struktur data. Banyak ditemukan pada sistem enterprise, aplikasi lama, konfigurasi sistem, serta pertukaran data antarplatform.

Spreadsheet (Excel / LibreOffice Calc)

Banyak digunakan karena memungkinkan pengguna mengelola data melalui antarmuka visual. Mendukung rumus, format, dan beberapa worksheet dalam satu file. Namun, untuk dataset sangat besar atau proses analisis yang harus dapat direproduksi, penggunaan bahasa pemrograman dan database umumnya lebih sesuai.

Data dari Database dan API

Database Relasional

Salah satu sumber data utama dalam sistem informasi. Menyimpan data dalam bentuk tabel yang memiliki hubungan tertentu dan diakses menggunakan **SQL (Structured Query Language)**. Contoh sistem: MySQL, PostgreSQL, MariaDB, SQL Server, Oracle.

Data pelanggan disimpan pada tabel pelanggan, data transaksi pada tabel transaksi, dan data produk pada tabel produk. Hubungan antar tabel dilakukan melalui **primary key** dan **foreign key**.

```
SELECT nama_produk,
  SUM(jumlah) AS total_terjual
FROM transaksi
GROUP BY nama_produk;
```

API (Application Programming Interface)

Memungkinkan satu aplikasi berkomunikasi dengan aplikasi lain secara terstruktur. Banyak layanan digital menyediakan API untuk mengakses data cuaca, data keuangan, data transportasi, data geografis, dan berbagai informasi lainnya.

API umumnya mengembalikan data dalam format JSON. Sebuah aplikasi mengirim request ke endpoint tertentu dan menerima response yang berisi data. Berguna untuk memperoleh data terkini tanpa harus mengunduh file secara manual.

Ketentuan Penggunaan API

- Autentikasi dan API key
- Rate limit (batas jumlah request)
- Ketentuan penggunaan data
- Dokumentasi endpoint yang perlu dipahami sebelum digunakan

Open Data dan Public Dataset

Open data merupakan data yang disediakan agar dapat diakses dan digunakan kembali oleh masyarakat sesuai dengan lisensi atau ketentuan tertentu. Dapat berasal dari pemerintah, organisasi internasional, lembaga pendidikan, maupun komunitas. Keberadaan open data sangat penting dalam pendidikan karena memungkinkan mahasiswa melakukan analisis menggunakan dataset dunia nyata.



Kriteria Memilih Dataset Publik

- Sumber data dan waktu publikasi
- Metode pengumpulan data
- Jumlah observasi dan variabel
- Kelengkapan dokumentasi
- Lisensi dan ketentuan penggunaan
- Relevansi dengan pertanyaan analisis



Ukuran Dataset untuk Pembelajaran

Dataset yang baik untuk pembelajaran tidak harus selalu berukuran besar. Dataset dengan beberapa ribu baris dan puluhan variabel sering kali sudah cukup untuk mempelajari proses pembersihan, EDA, visualisasi, dan pemodelan. Yang lebih penting adalah dataset memiliki struktur yang jelas dan memungkinkan mahasiswa menemukan pola yang bermakna.



Prinsip Reproducibility

Penggunaan open data mendorong prinsip reproducibility dalam analisis data. Apabila dataset dapat diakses oleh banyak orang, hasil analisis dapat diperiksa dan direplikasi oleh peneliti lain. Status sebagai dataset publik tidak selalu berarti data dapat digunakan tanpa batasan — setiap dataset dapat memiliki lisensi yang berbeda.

Pemeriksaan Awal Dataset

Pemeriksaan awal dataset merupakan langkah penting sebelum proses pembersihan atau analisis lebih lanjut. Tujuan utamanya adalah memahami ukuran, struktur, tipe variabel, nilai kosong, distribusi awal, serta kemungkinan masalah kualitas data. Tahap ini sering disebut sebagai **data inspection** atau **initial data profiling**.

Pertanyaan yang Perlu Dijawab

- Berapa jumlah baris dan kolom?
- Apa saja nama variabel?
- Apa tipe data setiap kolom?
- Apakah terdapat nilai kosong?
- Apakah terdapat duplikasi?
- Apakah nilai pada setiap variabel masuk akal?

Pemeriksaan awal juga dapat membantu menemukan kesalahan seperti usia bernilai negatif, tanggal yang tidak konsisten, atau kategori yang memiliki penulisan berbeda.

Fungsi Pandas untuk Pemeriksaan Awal

```
import pandas as pd

df = pd.read_csv("data_mahasiswa.csv")

print(df.head())    # baris pertama
print(df.shape)     # ukuran dataset
print(df.info())    # tipe data & non-null
print(df.describe()) # statistik dasar
```

- `head()`: melihat beberapa baris pertama
- `shape`: jumlah baris dan kolom
- `info()`: tipe data dan jumlah nilai non-null
- `describe()`: statistik deskriptif awal (rata-rata, std, min, kuartil, max)

Hasil pemeriksaan awal harus digunakan sebagai dasar untuk menentukan langkah berikutnya: penanganan missing values, konversi tipe data, atau pembersihan data.

Aktivitas Praktikum: Mengenal Struktur Dataset dengan Pandas

Pada praktikum kedua, mahasiswa mulai menggunakan Pandas untuk membaca dan mengeksplorasi dataset. Pandas menyediakan struktur data **DataFrame** yang memungkinkan pengguna mengelola data tabular secara efisien.

01

Praktik 1 – Membuat DataFrame Sederhana

```
data = {"NIM": ["M001","M002","M003"],
        "Nama": ["Andi","Budi","Citra"],
        "Semester": [4, 4, 6],
        "IPK": [3.21, 3.54, 3.72]}
df = pd.DataFrame(data)
```

DataFrame menyerupai tabel dengan baris dan kolom.
Lima observasi, empat variabel.

02

Praktik 2 – Memeriksa Struktur Data

```
print(df.shape)    # jumlah baris & kolom
print(df.columns)  # nama variabel
print(df.dtypes)   # tipe data kolom
```

03

Praktik 3 – Melihat Baris Data

```
print(df.head())  # baris pertama
print(df.tail())  # baris terakhir
```

Sangat penting ketika dataset memiliki ribuan atau jutaan baris.

04

Praktik 4 – Statistik Dasar

```
print(df.describe())
```

Menghasilkan ringkasan: jumlah data, rata-rata, standar deviasi, nilai minimum, kuartil, dan nilai maksimum untuk kolom numerik.

05

Praktik 5 & 6 – Membaca CSV dan Excel

```
df = pd.read_csv("data_mahasiswa.csv")
df_excel = pd.read_excel("data.xlsx")
```

Sumber data dapat berbeda, tetapi setelah dibaca menggunakan Pandas, data dapat diolah melalui struktur DataFrame yang sama.

Studi Kasus Mini: Platform Pembelajaran Daring

Sebuah platform pembelajaran daring memiliki dataset aktivitas mahasiswa yang akan digunakan untuk menganalisis keterlibatan mahasiswa selama mengikuti perkuliahan daring.

Atribut	Jenis Data	Skala	Visualisasi yang Cocok
student_id	Identifier	Nominal	Tidak divisualisasikan langsung
course_id	Identifier	Nominal	Tidak divisualisasikan langsung
login_count	Numerik Diskrit	Rasio	Histogram, boxplot
watch_time	Numerik Kontinu	Rasio	Histogram, scatter plot
quiz_score	Numerik	Interval/Rasio	Histogram, distribusi
assignment_status	Kategorikal	Nominal	Diagram batang
last_login	Temporal	Interval	Line chart, time series

Identifikasi jenis variabel ini penting karena setiap variabel memerlukan metode analisis yang berbeda. Distribusi **quiz_score** dapat ditampilkan menggunakan histogram, sedangkan jumlah mahasiswa berdasarkan **assignment_status** lebih tepat divisualisasikan menggunakan diagram batang.

Rangkuman, Latihan, dan Referensi

Rangkuman Bab 2

- Data dibedakan berdasarkan **struktur** (terstruktur, semi-terstruktur, tidak terstruktur), **sifat** (numerik, kategorikal), dan **skala pengukuran** (nominal, ordinal, interval, rasio)
- Dataset terdiri atas observasi dan variabel; dalam machine learning, variabel input disebut **feature** dan variabel yang diprediksi disebut **target**
- Data dapat diperoleh dari file CSV, spreadsheet, database, API, sensor, maupun repositori open data
- Sebelum analisis lebih lanjut, dataset harus diperiksa untuk mengetahui ukuran, tipe data, nilai kosong, duplikasi, serta kemungkinan masalah kualitas data menggunakan Pandas

Latihan Soal Pilihan

1. Jelaskan perbedaan antara data dan informasi beserta contohnya
2. Berikan masing-masing tiga contoh data terstruktur, semi-terstruktur, dan tidak terstruktur
3. Jelaskan empat skala pengukuran data dan contoh masing-masing
4. Mengapa nomor telepon yang terdiri atas angka tidak seharusnya diperlakukan sebagai data numerik untuk operasi matematika?
5. Jelaskan kelebihan dan kelemahan menggunakan dataset publik dibandingkan mengumpulkan data sendiri

Referensi Utama

- McKinney, W. (2022). *Python for Data Analysis*. O'Reilly Media.
- Provost, F., & Fawcett, T. (2013). *Data Science for Business*. O'Reilly Media.
- VanderPlas, J. (2016). *Python Data Science Handbook*. O'Reilly Media.
- Han, J., Kamber, M., & Pei, J. (2012). *Data Mining: Concepts and Techniques*. Morgan Kaufmann.